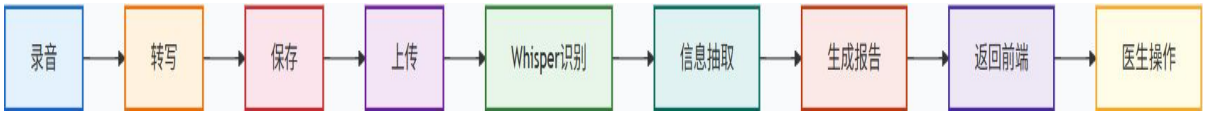
中医智能问诊系统整体框架设计文档

一、整体目标

系统要完成从医患语音对话采集到自动生成中医问诊报告的全过程。具体来说，医生和患者在医院问诊时正常交流，系统实时录音，并把语音转成文字；由于患者或医生可能使用扬州方言，所以语音识别模型需要适配普通话和方言混合场景。识别出的文字再交给本地大模型进行信息抽取、结构化整理，最终生成一份规范的中医问诊报告。医生可以在问诊界面查看、修改、下载报告。

二、系统流程



三、总体架构设计

整个架构分成五个模块。

3.1 前端问诊界面

界面分为六个区域：

区域	功能
患者信息区	姓名、性别、年龄、科室、就诊号、主诉简填
录音控制区	开始录音、暂停、继续、结束、上传
实时转写区	边问诊边显示文字
完整转写区	服务端识别后的完整文本

报告生成区	显示结构化问诊报告
医生操作区	修改、保存、下载 Word 或 PDF

前端必须完成三件关键事：实时采集麦克风音频；把音频分片上传服务端；接收服务端返回的实时文本和最终报告。

完整音频要保存为一个标准文件，命名规则：patient_id_visit_id_timestamp.wav

3.2 服务端接口层

服务端 AI 技术栈建议：Python FastAPI + WebSocket + PostgreSQL + MinIO 或本地文件存储。

FastAPI 负责接口服务，WebSocket 负责实时转写通信，PostgreSQL 保存结构化数据，MinIO 或本地磁盘保存录音和报告文件。

主要接口设计如下：

接口	方法	功能
/api/patient/create	POST	创建患者或问诊记录
/api/audio/stream	WebSocket	实时接收音频片段并返回转写
/api/audio/upload	POST	上传完整录音
/api/asr/transcribe	POST	调用 Whisper 完整转写
/api/report/generate	POST	调用本地大模型生成报告
/api/report/update	POST	医生修改报告
/api/report/download	GET	下载 Word 或 PDF 报告
/api/visit/history	GET	查询历史问诊记录

服务端内部数据流如下：

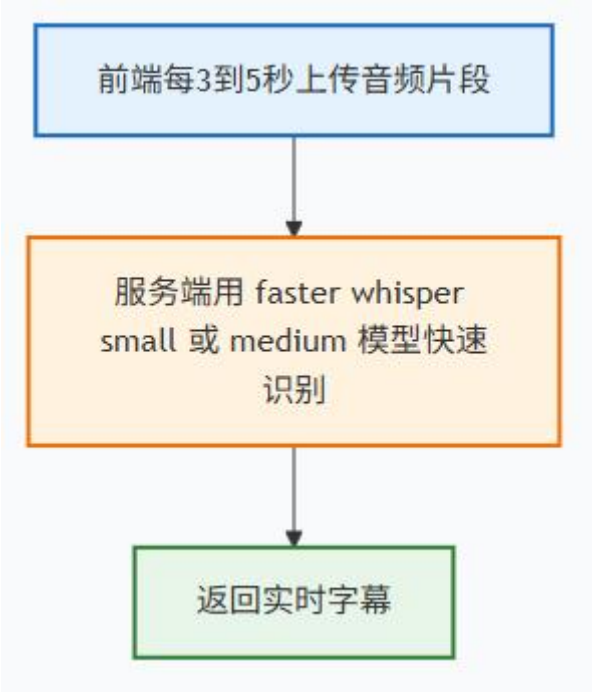
前端录音→WebSocket 上传音频片段→音频缓存与合并→Whisper 或 faster whisper 识别→实时返回初步文字→完整录音结束后重新高质量识别→文本清洗与医学纠错→本地大模型提取结构化信息→生成问诊报告→返回前端

3.3 语音识别模块

语音识别模块分成两个识别模式。

模式 A：实时识别

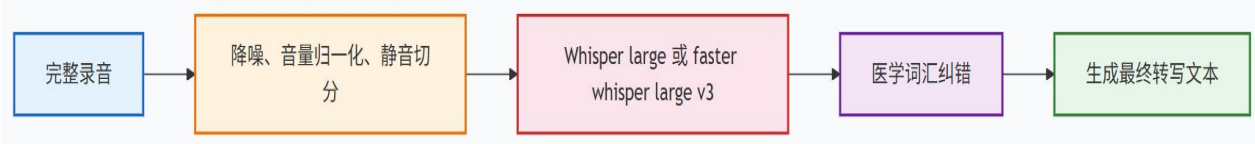
实时识别要求速度快，允许有少量错误。



faster whisper 的优势是推理速度和显存占用更适合服务端部署，官方说明其在相同准确率下比原始 whisper 更快，并支持 8 bit 量化。

模式 B：完整识别

问诊结束后，对完整录音重新识别一次。完整识别用于最终报告生成，因此要比实时识别更准确。



3.4 扬州方言处理策略

第一阶段：直接使用 Whisper 或 faster whisper 测试扬州方言识别效果。

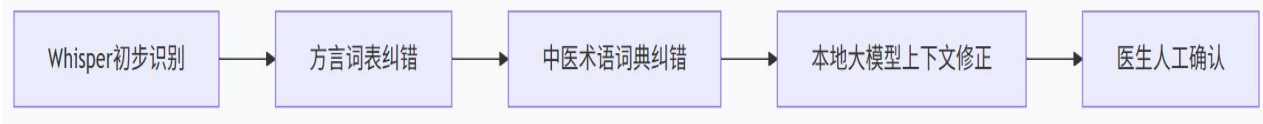
第二阶段：建立扬州方言，中医术语，普通话标准表达三列表。

第三阶段：积累足够语料后再做微调或后处理纠错。

可以建立如下词表：

扬州方言或口语表达	标准普通话表达	医学含义
胃里不落忍	胃部不舒服	胃脘不适
睡不着觉	失眠	睡眠障碍
嘴巴苦	口苦	肝胆湿热或其他相关症状
大便干	便秘	二便异常
身上冷	畏寒	寒热信息

方言识别不能只靠语音模型，需要进行人工修正:

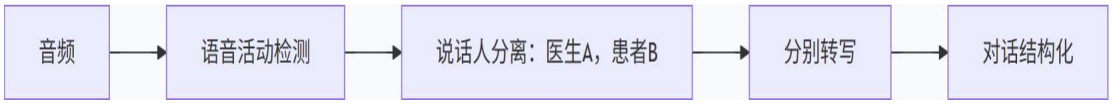


3.5 说话人区分模块

重点在提取关键词时，问诊报告不能把医生的问题误当成患者症状。

例如，医生问：“你有没有胸闷？”患者答：“没有。”如果不区分说话人，大模型可能会错误提取出“胸闷”。

因此建议加入说话人分离：



可选工具包括 pyannote audio 或 WhisperX。pyannote audio 提供说话人分离相关组件，能处理“谁在什么时候说话”的问题；WhisperX 也提供带词级时间戳和说话人分离的语音转写能力。

报告生成时保留的格式

例如：

医生：最近哪里不舒服？
患者：咳嗽有一个多月了。
医生：有没有痰？
患者：有，白痰，早上多一点。

这样大模型提取信息时准确率会高很多。

3.6 本地大模型信息抽取模块

本地大模型可以通过 Ollama、vLLM、LM Studio 或 Xinference 部署。Ollama 默认提供本地 API 服务，可通过本地接口调用模型，适合快速原型开发。

建议优先使用：Qwen 系列中文模型、DeepSeek 系列中文模型、Yi 系列中文模型，医学领域微调模型作为备选。

本地大模型不直接自由写报告，采用两步法。

第一步：结构化信息抽取

让大模型只输出 JSON，不直接写自然语言报告。

```
Plain Text
{
 "chief_complaint": "",
 "present_illness": {
  "onset_time": "",
  "main_symptoms": [],
  "symptom_duration": "",
  "aggravating_factors": "",
  "relieving_factors": "",
  "associated_symptoms": []
 },
 "past_history": "",
 "allergy_history": "",
 "medication_history": "",
 "tcm_inquiry": {
  "cold_heat": "",
  "sweating": "",
  "diet": "",
  "sleep": "",
  "urination": "",
  "defecation": "",
```

```
    "emotion": "",
    "pain": "",
    "thirst": "",
    "menstruation": "",
    "tongue": "",
    "pulse": ""
  },
  "negative_findings": [],
  "uncertain_information": [],
  "evidence_sentences": []
}
```

这里有一个关键原则：没有在对话中明确出现的信息，不能让模型补写。例如患者没说舌象，报告中应该写：舌象：未提及。不能自行编造相关内容。

第二步：基于 JSON 生成报告

报告模板如下：

中医智能问诊报告

1、基本信息

姓名：

性别：

年龄：

就诊日期：

科室：

2、主诉

患者主诉：

3、现病史

起病时间：

主要症状：

伴随症状：

加重或缓解因素：

4、既往史

既往疾病：

手术史：

过敏史：

用药史：

5、中医问诊信息

寒热：
汗出：
饮食：
睡眠：
二便：
情志：
疼痛：
口渴：
舌象：
脉象：

6、问诊摘要

根据本次医患对话，患者主要表现为……

7、待医生确认信息

以下内容在对话中表述不完整或存在不确定性：

8、医生修改意见

医生可在此处补充。

四、数据库设计

设计 6 张核心表。

4.1 患者表格 patient

字段	含义
patient_id	患者唯一编号
name	姓名
gender	性别
age	年龄
phone	联系方式，可脱敏
id_number_hash	可有可无
created_at	创建时间

4.2 问诊记录表 visit

字段	含义
visit_id	问诊编号
patient_id	患者编号
doctor_id	医生编号
department	科室
visit_time	就诊时间
status	录音中、已转写、已生成报告、已确认
created_at	创建时间

4.3 音频文件表 audio_file

字段	含义
audio_id	音频编号
visit_id	问诊编号
file_path	文件路径
duration	时长
sample_rate	采样率
format	文件格式
upload_time	上传时间

4.4 转写文本表 transcript

字段	含义
transcript_id	转写编号
visit_id	问诊编号
segment_index	片段序号
speaker	医生或患者
start_time	开始时间
end_time	结束时间
text	转写文本
confidence	置信度

4.5 结构化抽取表 extracted_info

字段	含义
extract_id	抽取编号
visit_id	问诊编号
json_data	抽取后的 JSON
model_name	使用的大模型
version	抽取版本
created_at	创建时间

4.6 报告表 report

字段	含义

report_id	报告编号
visit_id	问诊编号
report_text	报告正文
report_docx_path	Word 文件路径
report_pdf_path	PDF 文件路径
doctor_reviewed	医生是否确认
updated_at	更新时间

五、模型处理流程

建议采用下面这条比较稳的技术链：

其中“规则校验”非常重要。比如：

校验内容	规则
主诉	必须来源于患者陈述，不能来源于医生提问
症状	必须有原文证据
否定症状	必须明确识别“没有、不疼、不咳”等否定词
舌脉	未提及时不得自动生成
诊断	系统只生成“问诊摘要”，不直接下最终诊断
处方	不自动生成处方

六、前端页面具体设计

第一版页面分为 5 个部分。

部分 1：登录部分

角色分为：医生、管理员

部分 2：问诊部分

包含：患者基本信息、开始录音按钮、实时文字显示、当前录音时长、音频上传状态、结束问诊按钮。

部分 3：问诊转写部分

包含：完整对话文本、医生和患者分角色显示、每句话对应时间戳、可编辑转写错误、可标记方言词、可标记医学术语错误。

部分 4：报告生成部分

包含：一键生成报告、结构化字段展示、报告正文展示、医生修改区、保存按钮、下载 Word、下载 PDF。

部分 5：历史记录部分

支持：按患者姓名查询、按日期查询、按医生查询、按疾病或症状关键词查询、查看原始录音、查看转写文本、查看报告。

七、第一版原型功能范围

- **必须完成**

前端可以录音；前端可以实时显示转写文本；完整录音可以上传服务端；服务端可以调用 Whisper 或 faster whisper 转写；服务端可以调用本地大模型生成问诊报告；医生可以修改报告；医生可以下载 Word 报告；数据库保存患者、录音、转写和报告。

八、实施阶段安排

第一阶段：需求确认与数据规范设计

目标: 把系统边界、数据格式、报告模板先定下来。

具体任务: 设计中医问诊报告模板；设计医患对话采集知情同意书；设计患者信息脱敏规则；制定录音命名规则；制定标注规范；确定第一批采集科室和病

种。

输出成果：需求说明书、问诊报告模板、数据采集规范、伦理与知情同意材料、数据库字段表。

第二阶段：系统原型开发

目标：做出能跑通完整流程的最小系统。

具体任务：搭建前端录音页面；搭建 FastAPI 服务端；实现 WebSocket 音频上传；部署 faster whisper；部署本地大模型；实现报告生成接口；实现 Word 报告下载；建立数据库。

输出成果：可运行原型系统、前端问诊页面、后端 API 服务、Whisper 转写模块、大模型报告生成模块、Word 报告模板。

第三阶段：医院小规模试点

目标：采集真实问诊数据，测试系统可用性。

建议采集规模：30 到 50 例真实问诊录音，每例 5 到 20 分钟，总时长约 10 到 20 小时。

评估指标：

指标	目标
录音保存成功率	大于 95%
普通话转写可读性	医生基本能看懂
方言转写错误类型	能归类分析
报告字段完整率	大于 80%
医生修改时间	比手写或人工录入明显缩短
医生满意度	初步可接受

输出成果：试点数据集、错误分析报告、系统修改清单、第一版论文或项目材料基础数据。

第四阶段：扬州方言与中医术语优化

目标：提高真实场景识别和报告质量。

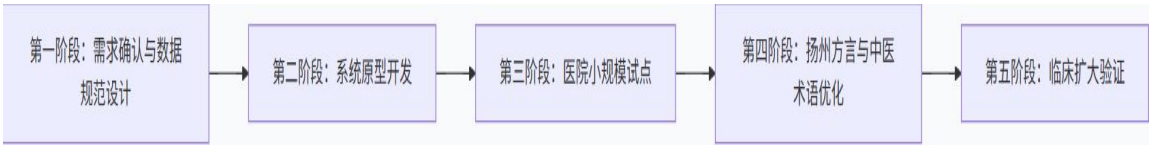
具体任务：建立扬州方言问诊语料库；建立中医术语词典；建立常见症状表达词表；统计 Whisper 错误类型；做转写后处理纠错；训练或微调方言纠错模型；必要时微调 Whisper。

建议先做“后处理纠错”，再考虑 Whisper 微调。因为医院初期数据量通常不够，直接微调容易过拟合。

输出成果：扬州方言问诊语料库、方言词表、中医术语纠错词典、转写质量评估报告、模型优化版本。

第五阶段：临床扩大验证

目标：形成较完整的科研和应用闭环。



建议采集规模：200 到 500 例问诊，覆盖多个医生，覆盖不同年龄患者，覆盖普通话和扬州方言混合场景。

评估指标：

类型	指标
语音识别	字错误率，句级可读性，医学术语识别准确率
方言识别	方言词识别准确率，方言转普通话准确率
信息抽取	主诉、现病史、二便、睡眠、寒热等字段准确率
报告质量	医生评分，修改率，平均节省时间
系统性能	实时延迟、上传稳定性、服务端并发能力

输出成果：临床验证数据、系统性能报告、问诊报告质量评价、科研论文基础、软件著作权材料、项目验收材料。

九、推荐技术选型

前端

Vue 3、TypeScript、Element Plus、WebSocket、MediaRecorder API

后端

Python、FastAPI、WebSocket、PostgreSQL、Redis、MinIO、Celery

语音识别

faster whisper medium：实时识别；faster whisper large v3：完整识别；WhisperX：词级时间戳和说话人分离备选；pyannote audio：说话人分离备选

本地大模型

Qwen 中文模型、DeepSeek 中文模型、Ollama 或 vLLM 部署

报告生成

docxtpl 生成 Word、LibreOffice 或 Python 工具转 PDF

部署方式

Docker Compose、Nginx、GPU 服务器、本地内网部署

十、服务器配置建议

原型阶段配置

CPU：16 核以上、内存：64 GB、GPU：RTX 4090 24 GB 或同级别、硬盘：2 TB SSD、系统：Ubuntu 22.04

医院试点阶段配置

CPU：32 核以上、内存：128 GB、GPU：A6000 48 GB 或 L40S 48 GB、硬盘：4 TB 到 8 TB SSD、存储：建议加 NAS 或独立存储服务器、系统：Ubuntu Server。如果预算有限，可以先用 RTX 4090 做原型，后续再升级。

十一、数据安全与伦理要求

这个项目涉及真实医患对话，必须提前考虑隐私合规。建议做到：

采集前签署知情同意；患者姓名、手机号、身份证号脱敏；原始录音加密存储；医生账号分权限访问；所有报告修改留痕；数据只在医院内网或本地服务

器处理；不把音频上传到外部云模型；科研使用时必须删除可识别身份信息。

尤其要注意：原始录音是高敏感数据，权限要比普通文本报告更严格。

十二、项目验收指标

软件功能指标

指标	目标
录音采集	支持连续录音不少于 30 分钟
实时转写	支持边录边显示
音频保存	支持原始录音自动归档
报告生成	支持一键生成结构化问诊报告
报告下载	支持 Word 或 PDF
历史查询	支持按患者、医生、日期检索

模型效果指标

指标	初期目标
普通话转写可读率	大于 85%
中医关键词识别准确率	大于 80%
主诉提取准确率	大于 85%
现病史提取准确率	大于 80%
中医问诊字段完整率	大于 75%
报告医生可接受率	大于 80%

应用效果指标

指标	目标
医生报告修改时间	较人工书写减少 30% 以上
报告生成时间	问诊结束后 1 分钟内生成初稿
录音归档成功率	大于 95%
系统稳定运行	单次连续运行不少于 8 小时

十三、可行产品版本

第一版开发功能表如下：

模块	第一版功能
登录	医生账号登录
患者管理	新建患者和问诊记录
录音	浏览器录音并保存
实时转写	分段上传并返回文字
完整转写	问诊结束后重新识别
报告生成	生成中医问诊报告
报告编辑	医生在线修改
报告导出	下载 Word
历史记录	查看历史问诊